

# جزوه امتحانی – داده‌های حجیم (Big Data Analytics)

استاد: دکتر فرساد زمانی بروجنی | امتحان: جزوه‌باز – ۹۰ دقیقه | منبع: لکچرهای ترم + نمونه سوالات + MMDS

در امتحان: ۱) اول چیت‌شیت و راهنمای صفحات را ببین (۲) موضوع را در جدول پیدا کن و به بخش برو (۳) پاسخ = تعریف یک‌خطی + فرمول + مثال کوتاه (۴) اگر شبیه نمونه استاد بود → بخش ۱۰

## چیت‌شیت سریع (صفحه اول امتحان)

### تعاریف یک‌خطی

| مفهوم                   | تعریف کوتاه                                                                      |
|-------------------------|----------------------------------------------------------------------------------|
| Shingle                 | دنباله $k$ توکن متوالی در سند. مثال $k=2$ از $abcbab \rightarrow \{ab, bc, ca\}$ |
| Jaccard                 | شباهت دو مجموعه $ A \cap B  /  A \cup B $                                        |
| MinHash                 | درهم‌سازی طوری که احتمال برابر شدن hash دو مجموعه = Jaccard باشد                 |
| LSH                     | فقط جفت‌های احتمالاً مشابه را candidate می‌کند                                   |
| Collaborative Filtering | توصیه بر اساس کاربران یا آیتم‌های مشابه                                          |
| Closed itemset          | هیچ ابرمجموعه‌ای با همان support ندارد                                           |
| Maximal itemset         | هیچ ابرمجموعه frequent ندارد                                                     |
| MapReduce               | پردازش موازی با دو تابع Map و Reduce + تحمل خرابی                                |

### فرمول‌های حیاتی

#### TF-IDF

$$\begin{aligned}TF(i, j) &= f(i, j) / \max_k f(k, j) \\IDF(i) &= \log_2(N / n(i)) \\TF-IDF &= TF(i, j) \times IDF(i)\end{aligned}$$

#### MinHash و Jaccard

$$\begin{aligned}J(A, B) &= |A \cap B| / |A \cup B| \\d_J &= 1 - J(A, B) \\Pr[h_\pi(C1) = h_\pi(C2)] &= J(C1, C2)\end{aligned}$$

#### LSH Banding (b باند، هر باند r سطر، شباهت s)

$$\begin{aligned}P(\text{candidate}) &= 1 - (1 - s^r)^b \\threshold &\approx (1/b)^{(1/r)}\end{aligned}$$

Euclidean L2 :  $\sqrt{\sum (x_i - y_i)^2}$   
 Manhattan L1 :  $\sum |x_i - y_i|$   
 Minkowski Lr :  $(\sum |x_i - y_i|^r)^{1/r}$   
 Chebyshev  $L_\infty$  :  $\max |x_i - y_i|$   
 Cosine sim :  $(x \cdot y) / (||x|| \times ||y||)$   
 Cosine dist :  $1 - \cos(\theta)$   
 Hamming : # differing positions  
 Edit :  $|X| + |Y| - 2 \times |LCS|$   
 Nominal :  $d = (p - m) / p$   
 Asym. binary :  $d = (r+s)/(q+r+s)$  ;  $J = q/(q+r+s)$

### Closed/Maximal و Association Rule

$\text{support}(A \Rightarrow B) = \text{support}(A \cup B)$   
 $\text{confidence}(A \Rightarrow B) = \text{support}(A \cup B) / \text{support}(A)$

$M \subseteq C \subseteq F$

### MapReduce — ضرب ماتریس در بردار $U = M \times V$

Map:  $\text{emit}(i, m_{ij} \times v_j)$  for each  $m_{ij}$   
 Reduce:  $u_i = \sum_j (m_{ij} \times v_j)$  for each  $i$

### K-Means / DBSCAN / BFR

$SSE = \sum ||x - \mu_{\text{cluster}(x)}||^2$

DBSCAN Core:  $|N_{\text{Eps}}(q)| \geq \text{MinPts}$   
 Border: near a Core, but not Core  
 Noise: neither

BFR:  $N, \text{SUM}, \text{SUMSQ}$   
 $\text{centroid}_i = \text{SUM}_i / N$   
 $\text{variance}_i = \text{SUMSQ}_i / N - (\text{SUM}_i / N)^2$

## مقایسه سریع

| موضوع                            | نکته طلایی                                                              |
|----------------------------------|-------------------------------------------------------------------------|
| RDBMS در برابر Cluster           | عمودی/گران/ACID در برابر افقی/commodity/replication و انتقال کد به داده |
| K-Means در برابر K-Medoids       | میانگین (حساس به پرت) در برابر نقطه واقعی داده (مقاوم‌تر)               |
| Closed در برابر Maximal          | Closed اطلاعات support را نگه می‌دارد؛ Maximal فقط مرز را               |
| Cosine در برابر اقلیدسی برای متن | Cosine برای بردارهای sparse متن بهتر است                                |
| Combiner                         | فقط وقتی Reduce انجمنی و جابجایی‌پذیر باشد                              |

## راهنمای صفحات / ایندکس سریع (اول جزوه)

در امتحان: کلمه کلیدی سوال را اینجا پیدا کن → برو به بخش گفته‌شده.

| کلمه کلیدی سوال                    | بخش          | چه بنویسی                           |
|------------------------------------|--------------|-------------------------------------|
| Shingle                            | ۶§ + چیت شیت | تعریف + مثال abcab                  |
| Jaccard                            | ۶§ + چیت شیت | فرمول $ u / n $                     |
| MinHash / درهم سازی مین            | ۶§ + چیت شیت | تعریف + $Pr = Jaccard$              |
| Collaborative Filtering            | ۱§ + چیت شیت | User-based / Item-based             |
| Cluster در برابر RDBMS             | ۲§           | جدول تفاوت ها                       |
| Matrix-Vector / ضرب ماتریس × بردار | ۵§           | Map و Reduce کامل                   |
| TF-IDF                             | ۱§ و ۱۰§ س۴  | سه فرمول + عدد                      |
| Apriori                            | ۸§ و ۱۰§ س۵  | مراحل Pass به Pass                  |
| LSH / banding                      | ۶§           | فرمول $b^{(s^r-1)-1}$               |
| Support / Confidence               | ۸§           | دو فرمول قانون                      |
| Closed / Maximal                   | ۸§           | تعریف + $M \subseteq C \subseteq F$ |
| فاصله اقلیدسی / منتهن $\infty L$   | ۷§           | فرمول ها                            |
| تشابه اسمی / دودویی                | ۷§           | $q, r, s, t$ و $p/(p-m)$            |
| MapReduce تعریف                    | ۳§           | سه مرحله + Combiner                 |
| خرابی نودها                        | ۳§           | جدول Master/Map/Reduce              |
| MapReduce با Join                  | ۴§           | کلید = صفت مشترک                    |
| Clustering تعریف                   | ۹§           | min intra / max inter               |
| K-Means                            | ۹§           | مراحل + مثال                        |
| DBSCAN                             | ۹§           | Core / Border / Noise               |
| BFR / CURE                         | ۹§           | خلاصه ها / نماینده ها               |
| Hadoop / HDFS                      | ۲§           | Scalable + Fault Tolerant           |
| نمونه سوالات استاد با حل           | ۱۰§          | اول اینجا را ببین                   |

شماره بخش ها: ۱§ مقدمه و ۴§ · MapReduce ۳§ · Cluster / RDBMS ۲§ · TF-IDF جبر رابطه ای · ۵§ ضرب ماتریس · ۶§  
 Similar Items فاصله ها · ۸§ ۹§ · Frequent Itemsets خوشه بندی · ۱۰§ حل نمونه سوالات

## ۱§ — مقدمه Big Data و مفاهیم پایه

### تعریف Big Data (سه V)

- **Volume:** حجم آن قدر زیاد است که با سیستم های معمولی قابل پردازش نیست.
- **Velocity:** داده با نرخ بالا تولید می شود.
- **Variety:** داده در شکل های مختلف است (ساخت یافته / نیمه ساخت یافته / بدون ساختار).

### داده کاوی

استخراج الگو، مدل یا دانش مفید از داده. دیدگاه ها: آماری → توزیع ها؛ یادگیری ماشین → مدل پیش بینی؛ الگوریتمی → روش مقیاس پذیر.

### دو تکنیک محاسباتی مهم

1. خلاصه سازی داده ها (مثل PageRank و خوشه بندی)

2. استخراج ویژگی (مثل frequent itemsets، شناسایی مشابه، توصیه‌گر)

## PageRank (ایده)

رتبه‌بندی صفحات وب بر اساس لینک‌ها: اهمیت یک صفحه تابعی از اهمیت صفحاتی است که به آن لینک داده‌اند.

## اصل Bonferroni

در داده عظیم، رویدادهای بسیار نادر هم ممکن است زیاد رخ دهند؛ پس بسیاری از یافته‌ها می‌توانند False Positive باشند.

عدد e

$$\begin{aligned}e &\approx 2.718 \\ e &= \lim_{n \rightarrow \infty} (1 + 1/n)^n \\ (1 + a)^b &\approx e^{(a \times b)} \\ (1 - p)^n &\approx e^{(-p \times n)}\end{aligned}$$

## TF-IDF (خیلی مهم)

کلمه مفید: در تعداد کمی سند، تکرار زیاد دارد. Stop word ها در همه اسناد پرتکرارند  $\rightarrow$  IDF نزدیک صفر.

فرمول

$$\begin{aligned}TF(i,j) &= f(i,j) / \max_k f(k,j) \\ IDF(i) &= \log_2(N / n(i)) \\ TF-IDF &= TF(i,j) \times IDF(i)\end{aligned}$$

$f(i,j)$  = count of word i in doc j  
 $\max_k f(k,j)$  = max word count in doc j  
N = number of documents  
 $n(i)$  = docs containing word i

مثال نمونه سوال استاد

$$\begin{aligned}N &= 1024, \quad n(w) = 128, \quad f(w,j) = 10, \quad \max = 100 \\ TF &= 10 / 100 = 0.1 \\ IDF &= \log_2(1024 / 128) = \log_2(8) = 3 \\ TF-IDF &= 0.1 \times 3 = 0.3\end{aligned}$$

## Collaborative Filtering (فیلترینگ مشارکتی)

روشی در سیستم‌های توصیه‌گر: بر اساس رفتار یا امتیاز کاربران مشابه، آیتم‌هایی به کاربر هدف پیشنهاد می‌شود.

- **User-based**: کاربران شبیه کاربر هدف را پیدا کن  $\rightarrow$  آیتم‌های مورد علاقه آن‌ها را پیشنهاد بده
- **Item-based**: آیتم‌های شبیه آیتم‌های پسندیده‌شده را پیشنهاد بده

در درس به Recommendation Engine (مثل Netflix و Amazon) و Behavioral Data اشاره شده است.

## ۲۴ Cluster Computing در برابر RDBMS

### محدودیت‌های RDBMS

1. مقیاس‌پذیری گران/ضعیف در حد ترابایت و پتابایت
2. سرعت
3. تحمل خرابی
4. پردازش‌های پیشرفته
5. پرس‌وجویپذیری روی داده حجیم

## ویژگی‌های Cluster Computing

1. High Availability
2. Fault Tolerance
3. Data Replication
4. Load Balancing
5. Automated Failover
6. Backup and Recovery
7. Monitoring and Alerting
8. Scalability (افقی)

| موضوع       | RDBMS سنتی            | Cluster / Hadoop          |
|-------------|-----------------------|---------------------------|
| سخت‌افزار   | سرور گران high-end    | commodity server ارزان    |
| مقیاس       | غالباً عمودی          | افقی                      |
| داده        | ساخت‌یافته، جدولی     | ساخت‌یافته + بدون ساختار  |
| تحمل خرابی  | سخت‌افزاری/گران       | نرم‌افزاری با replication |
| ایده پردازش | انتقال داده به سمت کد | انتقال کد به سمت داده     |
| مدل         | SQL و ACID قوی        | MapReduce / NoSQL         |

## SQL در برابر NoSQL

- **SQL**: اسکیمای ثابت، ACID، مقیاس عمودی، مناسب تراکنش و پرس‌وجوی پیچیده
- **NoSQL**: اسکیمای انعطاف‌پذیر، مقیاس افقی، مناسب داده حجیم و متنوع

## Hadoop

- دو ویژگی: **Fault Tolerant + Scalable**
- اجزا: HDFS + MapReduce API
- Daemon ها: NameNode , DataNode , JobTracker , TaskTracker
- HDFS فایل را به chunk تقسیم می‌کند؛ معمولاً 3 = replication
- حالت‌ها: Standalone / Pseudo-Distributed / Fully Distributed

## ۳§ — MapReduce

**تعریف:** سبک محاسباتی برای پردازش داده حجیم با تحمل خرابی. کاربر فقط دو تابع Map و Reduce می‌نویسد.

### سه مرحله

1. **Map**: هر Map Task یک یا چند chunk می‌گیرد و زوج‌های (key, value) تولید می‌کند.
2. **Shuffle / Sort / Group**: Master خروجی‌ها را بر اساس key گروه‌بندی می‌کند.
3. **Reduce**: برای هر کلید، مقادیر را ترکیب می‌کند.

### شکل کلی

$$(k, v_1), (k, v_2), \dots \rightarrow (k, [v_1, v_2, \dots, v_n])$$
$$(k, [v_1, \dots, v_n]) \rightarrow (k, v')$$

## Combiner

اگر Reduce جابجایی‌پذیر و انجمنی باشد، بخشی از Reduce روی همان نود Map انجام می‌شود تا ترافیک شبکه کم شود.

## مثال Word Count

بدون Combiner:  $(w, 1)$  چند بار  
 با Combiner:  $(w, n_i)$  جمع نهایی Reduce و در

## مدیریت خرابی

| خرابی         | اقدام                                        |
|---------------|----------------------------------------------|
| Master        | معمولاً کل Job باید از نو شروع شود           |
| Map Worker    | Map Task ها دوباره روی نود سالم اجرا می‌شوند |
| Reduce Worker | Reduce Task دوباره اجرا می‌شود               |

**Workflow Systems:** توسعه MR از دو مرحله ساده به DAG از توابع (Clustera , Hyracks).

**Recursive MR:** PageRank و Transitive Closure با تکرار Job تا همگرایی.

## PageRank iteration

$$v^{(t+1)} = M \times v^{(t)}$$

## ۴§ — جبر رابطه‌ای با MapReduce

| عملیات           | Map                           | Reduce                        |
|------------------|-------------------------------|-------------------------------|
| Selection        | اگر شرط برقرار بود: $(t, t)$  | عبور همان زوج                 |
| Projection       | $(t', t)$ با صفات انتخاب شده  | حذف تکراری‌ها                 |
| Union            | $(t, t)$ از R و S             | یکبار خروجی                   |
| Intersection     | $(t, t)$                      | فقط اگر دو مقدار باشد         |
| Difference $R-S$ | از $R: (t, R)$ از $S: (t, S)$ | فقط اگر فقط R آمده باشد       |
| Natural Join     | کلید = صفت مشترک B            | ترکیب همه جفت‌های R و S       |
| Grouping + Agg   | کلید = صفات گروه              | SUM / COUNT / AVG / MIN / MAX |

## Join ساده $R(A,B) \bowtie S(B,C)$

Map from R: `emit( b , (R, a) )`  
 Map from S: `emit( b , (S, c) )`  
 Reduce: `for each b, combine all a with all c → (a, b, c)`

## ۵§ — ضرب ماتریس با MapReduce

### ۵.۱ ماتریس $\times$ بردار (سوال امتحانی)

#### هدف و الگوریتم

$U = M \times V$   
 $u_i = \sum_j (m_{ij} \times v_j)$

Map: `emit( i , m_{ij} \times v_j )` for each  $m_{ij}$   
 Reduce: `u_i = sum of values` for each  $i$

### مثال حل شده

$$M = \begin{bmatrix} 1 & 0 & 5 \\ 7 & 3 & 0 \\ 1 & 3 & 5 \end{bmatrix} \quad V = \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix}$$

Map row1: (1,2) , (1,0) , (1,30)

Map row2: (2,14), (2,12), (2,0)

Map row3: (3,2) , (3,12), (3,30)

Reduce:

$$u_1 = 2+0+30 = 32$$

$$u_2 = 14+12+0 = 26$$

$$u_3 = 2+12+30 = 44$$

$$U = [32, 26, 44]^T$$

## ۵.۲ ماتریس $\times$ ماتریس (دو Job)

### الگوریتم

$$P = M \times N$$

$$p_{ik} = \sum_j (m_{ij} \times n_{jk})$$

Job1 Map: emit( j , [M, i, m\_ij] )

emit( j , [N, k, n\_jk] )

Job1 Reduce: emit( (i,k) , m\_ij  $\times$  n\_jk )

Job2 Reduce: p\_ik = sum of values for key (i,k)

### نتیجه مثال

$$N = \begin{bmatrix} 2 & 0 \\ 4 & 8 \\ 6 & 2 \end{bmatrix} \quad P = \begin{bmatrix} 32 & 10 \\ 26 & 24 \\ 44 & 34 \end{bmatrix}$$

## ۶.۵ Finding Similar Items —

### Pipeline

Document  $\rightarrow$  Shingling  $\rightarrow$  Sets  $\rightarrow$  MinHash  $\rightarrow$  Signatures  $\rightarrow$  LSH  $\rightarrow$  Candidates  $\rightarrow$  Exact check

## ۶.۱ Shingle

**تعریف:** k-shingle یعنی دنباله k توکن پشت سرهم در سند.

### مثال

$$D = \text{ab cab} , \quad k = 2$$

$$S(D) = \{\text{ab}, \text{bc}, \text{ca}\}$$

• bag-of-words ترتیب را از دست می‌دهد؛ shingle تا حدی ترتیب را نگه می‌دارد.

• اسناد کوتاه  $\approx k=5$  ؛ اسناد بلند  $\approx k=10$

## Jaccard ۶.۲

### فرمول و مثال

$$J(A,B) = |A \cap B| / |A \cup B|$$
$$d_J = 1 - J(A,B)$$

$$A = \{a,b,c,d\} , B = \{b,c,e\}$$
$$|A \cap B| = 2 , |A \cup B| = 5$$
$$J = 2/5 = 0.4 , d = 0.6$$

## MinHash ۶.۳

**تعریف:** تبدیل مجموعه بزرگ به امضای کوتاه طوری که تشابه تقریباً حفظ شود.  
ایده: permutation تصادفی  $\pi$  ؛  $h\pi(C) =$  اولین عنصر C در ترتیب  $\pi$ .

### خاصیت طلایی و signature

$$\Pr[ h\pi(C1) = h\pi(C2) ] = J(C1, C2)$$

$$\text{sig}(C) = [h1(C), h2(C), \dots, hK(C)]$$
$$\text{estimated similarity} = (\# \text{ equal rows}) / K$$

$$h(a,b)(x) = ((a \times x + b) \bmod p) \bmod N$$
$$\text{if row has 1: } \text{sig}[i] = \min(\text{sig}[i], h_i(\text{row}))$$

## LSH ۶.۴

ماتریس signature با  $n$  سطر را به  $b$  باند تقسیم کن؛ هر باند  $r$  سطر دارد ( $n = b \times r$ ). اگر دو ستون در حداقل یک باند برابر باشند  $\rightarrow$  candidate.

### فرمول و مثال

$$P(\text{candidate}) = 1 - (1 - s^r)^b$$
$$\text{threshold} \approx (1/b)^{(1/r)}$$

$$b=20 , r=5 , s=0.8 \rightarrow P \approx 0.99965$$
$$b=20 , r=5 , s=0.3 \rightarrow P \approx 0.047$$

$$r \uparrow \rightarrow FP \downarrow , FN \uparrow$$
$$b \uparrow \rightarrow FN \downarrow , FP \uparrow$$

## ۷۵ – سنج‌های فاصله و تشابه تاپل‌ها

### اصول Metric

$$d(x,y) \geq 0 .1$$

$$d(x,y) = 0 \text{ اگر و فقط اگر } x = y .2$$

$$d(x,y) = d(y,x) .3$$

$$d(x,y) \leq d(x,z) + d(z,y) .4$$



## فرمول فاصله ها و مثال

Euclidean:  $\sqrt{\sum (x_i - y_i)^2}$   
 Manhattan:  $\sum |x_i - y_i|$   
 Minkowski:  $(\sum |x_i - y_i|^r)^{1/r}$   
 $L_\infty$ :  $\max |x_i - y_i|$   
 Cosine:  $(x \cdot y) / (||x|| ||y||)$   
 Hamming: # differing positions  
 Edit:  $|X| + |Y| - 2 \times |LCS|$

Example Euclidean:

$x=(1,2), y=(4,6)$   
 $d = \sqrt{9+16} = 5$

Example Hamming:

$X=10101, Y=11110 \rightarrow d = 3$

## ماتریس داده و عدم تشابه

• **Data Matrix**: سطر = تاپل ، ستون = صفت

• **Dissimilarity Matrix**: فاصله بین تاپل‌ها؛ قطر = 0

## بر اساس نوع صفت

Nominal:  $d = (p - m) / p$   
 Sym. binary:  $d = (r+s) / (q+r+s+t)$   
 Asym. binary:  $d = (r+s) / (q+r+s)$   
 Jaccard binary:  $J = q / (q+r+s)$

$q=\text{both } 1, r=(0,1), s=(1,0), t=\text{both } 0$

Example nominal:

$x=(\text{تهران, مجرد, M, قرمز})$   
 $y=(\text{تهران, متاهل, F, قرمز})$   
 $m=2, p=4 \rightarrow d=(4-2)/4 = 0.5$

## ۸۵ — Frequent Itemsets , Apriori , Closed , Maximal

### تعاریف

$\text{support}(X)$  = fraction of transactions containing X

Frequent:  $\text{support}(X) \geq \text{minsup}$

$\text{support}(A \Rightarrow B) = \text{support}(A \cup B)$

$\text{confidence}(A \Rightarrow B) = \text{support}(A \cup B) / \text{support}(A)$

| نوع     | تعریف                                  |
|---------|----------------------------------------|
| Closed  | هیچ ابرمجموعه‌ای با همان support ندارد |
| Maximal | هیچ ابرمجموعه frequent ندارد           |

### رابطه طلایی

$M \subseteq C \subseteq F$

**اصل Apriori:** اگر itemset پرتکرار باشد، همه زیرمجموعه‌هایش هم پرتکرارند.

1. Pass1: شمارش itemset-1ها  $\rightarrow L1$

2. از  $L(k-1)$  کاندیدهای  $C_k$  بساز

3. با اصل Apriori هرس کن

4. support را بشمار  $\rightarrow L_k$

5. تکرار تا  $L_k$  تهی شود

**PCY:** در Pass1 جفت‌ها را hash به bucket کن. در Pass2 جفت فقط وقتی کاندید است که هر دو item frequent باشند و bucket هم frequent باشد.

**CHARM:** استخراج Closed با tidset intersection.

## ۹۵ – خوشه‌بندی Clustering

**هدف:** فاصله درون‌خوشه‌ای کمینه، فاصله بین‌خوشه‌ای بیشینه. بدون سرپرست است.

• Partitioning: K-Means , K-Medoids , PAM , CLARA , CLARANS

• Hierarchical: AGNES , DIANA , BIRCH , CURE

• Density-based: DBSCAN , OPTICS , DENCLUE

• Grid-based: STING , CLIQUE

### K-Means

1. انتخاب  $k$  مرکز اولیه

2. تخصیص هر نقطه به نزدیک‌ترین مرکز

3. به‌روزرسانی مراکز با میانگین

4. تکرار تا ثبات

ضعف‌ها: نیاز به  $k$ ، حساس به init و نویز، خوشه تقریباً کروی، بهینه محلی

### K-Medoids / PAM / CLARA / CLARANS

• Medoid = شیء واقعی داده (مقاوم‌تر به پرت)

• PAM: تعویض medoid اگر هزینه کم شود

• CLARA: PAM روی نمونه‌های تصادفی

• CLARANS: جستجوی تصادفی همسایه‌ها

| Linkage  | فاصله دو خوشه      |
|----------|--------------------|
| Single   | کمینه فاصله اعضا   |
| Complete | بیشینه فاصله اعضا  |
| Average  | میانگین همه زوج‌ها |
| Centroid | فاصله مراکز        |

DBSCAN: Eps , MinPts  
Core / Border / Noise

BFR (large Euclidean):  
N , SUM , SUMSQ  
DS / CS / RS

CURE: several representative points per cluster  
(good for non-spherical shapes)

Points: A(1,1), B(1,2), C(4,4), D(5,4)  
Init:  $\mu_1=A(1,1)$  ,  $\mu_2=C(4,4)$

Assign:  $C_1=\{A,B\}$  ,  $C_2=\{C,D\}$   
Update:  $\mu_1=(1, 1.5)$  ,  $\mu_2=(4.5, 4)$

## § ۱۰ – حل کامل نمونه سوالات استاد

امتحان نمونه: داده‌های حجیم — ۹۰ دقیقه — ۱۰ نمره توصیفی

### سوال ۱ (۲ نمره) — تعریف مفاهیم

**الف) Min-hashing:** ساخت امضای کوتاه از مجموعه‌های بزرگ طوری که احتمال برابر شدن hash دو مجموعه برابر Jaccard باشد.

$$\Pr[ h(C_1) = h(C_2) ] = J(C_1, C_2)$$

**ب) Collaborative Filtering:** روش توصیه‌گر مبتنی بر مشارکت؛ با یافتن کاربران/آیتم‌های مشابه، آیتم مناسب پیشنهاد می‌شود (مثل Netflix و Amazon).

**ج) Jaccard Similarity:**

$$J(A,B) = |A \cap B| / |A \cup B|$$

**د) Shingle:** دنباله k توکن متوالی در سند؛ برای مقایسه near-duplicate استفاده می‌شود.

### سوال ۲ (۲ نمره) — Cluster در برابر RDBMS

**RDBMS سنتی:** مقیاس غالباً عمودی و گران، داده ساخت‌یافته، ACID قوی، سرورهای قدرتمند؛ در حجم خیلی بالا محدود است.

**Cluster Computing:** مقیاس افقی با commodity servers, replication و failover, high availability, load balancing, تحمل خرابی نرم‌افزاری ارزان‌تر، انتقال کد به سمت داده (Hadoop/MapReduce).

### سوال ۳ (۲ نمره) — ضرب ماتریس×بردار با MapReduce

$$U = M \times V$$

- 1) Map:  $\text{emit}(i, m_{ij} \times v_j)$  for each  $m_{ij}$
- 2) Shuffle: group by i
- 3) Reduce:  $u_i = \sum \text{values}$  for key i

اگر V در حافظه جا شود همه Mapperها آن را دارند. مثال عددی در §۵.

## سوال ۴ (۲ نمره) — TF-IDF

$N=1024$  ,  $n(w)=128$  ,  $f(w,j)=10$  ,  $\max=100$

TF =  $10/100 = 0.1$

IDF =  $\log_2(1024/128) = \log_2(8) = 3$

TF-IDF =  $0.1 \times 3 = 0.3$

پاسخ نهایی: 0.3

## سوال ۵ (۲ نمره) — MST = 0.3 با Apriori

| TID | اقدام         |
|-----|---------------|
| 1   | a, b          |
| 2   | b, c          |
| 3   | a, b, c       |
| 4   | d, e, f       |
| 5   | a, b, c       |
| 6   | d, f          |
| 7   | c, d, e, f    |
| 8   | a, b, c, d, e |

### آستانه و Passها

$\text{minsup} = 0.3 \times 8 = 2.4 \Rightarrow \text{need count} \geq 3$   
(because  $2/8 = 0.25 < 0.3$ )

Pass1 counts:

$a=4, b=5, c=5, d=4, e=3, f=3$

$L1 = \{a, b, c, d, e, f\}$

Pass2 frequent pairs:

$ab=4, ac=3, bc=4, de=3, df=3$

$L2 = \{ab, ac, bc, de, df\}$

( $cd=2, ce=2, ef=2$  are NOT frequent)

Pass3:

$abc = 3 \rightarrow \text{frequent}$

$\{def\}$  not candidate ( $ef$  not in  $L2$ )

$L3 = \{abc\}$

Final:

1-item:  $a, b, c, d, e, f$

2-item:  $ab, ac, bc, de, df$

3-item:  $abc$

چکلیست ۳۰ ثانیه‌ای: (۱) تعریف یک خطی؟ (۲) فرمول؟ (۳) مثال عددی؟ (۴) تفاوت با مفهوم نزدیک؟