

چیت‌شیت یک‌نگاهی – داده‌های حجیم

پاسخ امتحان = تعریف یک‌خطی + فرمول + مثال کوتاه. جزئیات بیشتر در جزوه اصلی (۱۰٪ تا ۱۰٪).

MapReduce ماتریس×بردار

Map: $(i, m_{ij} \times v_j)$
Reduce: $u_i = \sum \text{values}$

مثال:

$M = [[1,0,5], [7,3,0], [1,3,5]]$
 $V = [2,4,6]$
 $\rightarrow U = [32,26,44]$

Association / Closed

$\text{sup}(A \Rightarrow B) = \text{sup}(A \cup B)$
 $\text{conf} = \text{sup}(A \cup B) / \text{sup}(A)$
 $M \subseteq C \subseteq F$

Cluster vs RDBMS

RDBMS: vertical, ACID, expensive
Cluster: horizontal, commodity, replication, code-data

Clustering

goal: min intra / max inter
K-Means: centroid + SSE
K-Medoids: real point
DBSCAN: Core/Border/Noise
BFR: N, SUM, SUMSQ

Apriori (اصل)

همه X frequent $\Rightarrow$ اگر
frequent زیرمجموعه‌ها یش

مثال $MST=0.3$, $n=8$
 $\Rightarrow \text{count} \geq 3$
 $L2 = \{ab, ac, bc, de, df\}$
 $L3 = \{abc\}$

تعاریف

مفهوم	یک خط
Shingle	دنباله k توکن متوالی
Jaccard	$ A \cap B / A \cup B $
MinHash	$\text{Jaccard} = [h \text{ برابر}]Pr$
LSH	فقط candidateهای مشابه
Collab. Filtering	توصیه با کاربران/آیتم‌های مشابه
Closed	بدون ابرمجموعه با همان support
Maximal	بدون ابرمجموعه frequent
MapReduce	Map + Reduce + fault tolerance

TF-IDF

$TF = f / \max_f$
 $IDF = \log_2(N / n)$
 $TF-IDF = TF \times IDF$

مثال: $N=1024, n=128, f=10, \max=100$
 $\rightarrow 0.1 \times 3 = 0.3$

Jaccard / MinHash / LSH

$J = |A \cap B| / |A \cup B|$
 $Pr[h_m(C1)=h_m(C2)] = J$

$P = 1 - (1 - s^r)^b$
 $\text{thr} \approx (1/b)^{(1/r)}$

فاصله‌ها

$L2: \sqrt{\sum (x_i - y_i)^2}$
 $L1: \sum |x_i - y_i|$
 $Lr: (\sum |x_i - y_i|^r)^{(1/r)}$
 $L\infty: \max |x_i - y_i|$
 $\text{Cos}: (x \cdot y) / (||x|| ||y||)$
 $\text{Ham}: \# \text{ diffs}$
 $\text{Edit}: |X| + |Y| - 2|LCS|$
 $\text{Nom}: (p-m)/p$
 $\text{Bin}: (r+s)/(q+r+s)$

بخش جزوه	سوال نمونه
۱۰٪ - ۱٪ / چیت‌شیت	تعاریف .../MinHash/Jaccard
۲٪ - ۱۰٪ / ۲٪	Cluster vs RDBMS
۵٪ - ۱۰٪ / ۳٪	Matrix×Vector
۱٪ - ۱۰٪ / ۴٪	TF-IDF
۸٪ - ۱۰٪ / ۵٪	Apriori